

Ames Housing Question-Driven EDA

교육용 Ames Housing 데이터의 핵심 특성과 전처리 이슈를 질문 중심으로 요약한 2페이지 보고서

핵심 결론

팀원: 박지훈 · 윤명진 · 홍은비 | 분석 대상: 교육용 Ames Housing 2,930건

가격은 오른쪽으로 크게 치우치며(왜도 1.74), 품질·생활면적·차고 규모가 가격 차이를 가장 잘 설명한다. 반면 차고 건축연도 결측의 대부분은 '누락'이 아니라 '차고 없음'이라는 구조적 의미를 가진다. 따라서 모델링 전에는 의미 기반 결측 처리, 로그 변환, 오류·중복 검증, 희소 범주 통합, 인코딩과 스케일링을 우선해야 한다.

관측치

2,930

관측 단위는 주택 매매 1건

가격 왜도

1.74

양수일수록 오른쪽 꼬리가 긴 분포

Garage 연도 결측

5.4%

차고 건축연도 결측 비율

완전 중복

3

모든 15개 열이 동일한 행

가격을 설명하는 핵심 변수

Pearson 상관은 선형 관계의 강도를 비교한 값이다. Overall_Qual(0.799)이 가장 강했고 Gr_Liv_Area(0.707), Garage_Cars(0.648), Total_Bsmt_SF(0.632)가 뒤따랐다. 품질은 면적보다 가격 수준을 더 선명하게 총화하며, 동일 면적에서도 품질이 높을수록 가격대가 상승한다. 다만 상관은 인과를 뜻하지 않는다.

수치형 변수와 SalePrice의 상관계수

전체 2,930건, Pearson r; 품질과 생활면적이 가장 강한 양의 관계

변수	상관계수	순위
Overall_Qual	0.8	1
Gr_Liv_Area	0.71	2
Garage_Cars	0.65	3
Total_Bsmt_SF	0.63	4
Year_Built	0.56	5
Full_Bath	0.55	6
Garage_Yr_Blt	0.53	7
Lot_Area	0.27	8

분포와 범주에서 드러난 패턴

SalePrice 평균은 \$180,796, 중앙값은 \$160,000으로 고가 주택이 평균을 끌어올린다. $\log_{1p}(\text{SalePrice})$ 의 왜도는 -0.01로 거의 대칭이 되어 회귀 타깃 변환 후보가 된다. 지역 중앙값은 MeadowV \$88,250에서 StoneBr \$319,000까지 약 3.6배 차이가 난다. 주방 품질 중앙값도 Fa \$107,750

→ TA \$136,500 → Gd \$201,000 → Ex \$325,624로 순서형 효과가 뚜렷하다. 단, Neighborhood의 GrnHill(2건)·Landmrk(1건), Kitchen_Qual=Po(1건)는 추정이 불안정하므로 희소 범주 통합이나 교차검증이 필요하다.

데이터 품질 이슈는 ‘삭제’보다 ‘의미 확인’이 먼저

IQR 후보는 오류 확정이 아니라 재검토 목록이다. Overall_Cond가 252건(8.60%)으로 가장 많지만 1~9의 유효 등급이므로 자동 제거하면 안 된다. 실제로 점검 우선순위가 높은 것은 Garage_Yr_Blt=2207 1건, 완전 중복 3행, 그리고 생활면적 4,000ft² 초과 5건 중 가격이 \$160k~\$185k에 그친 Edwards 3건이다. 후자는 실제 특수 매물일 수 있어 원자료 확인 후 처리한다.

IQR 기준 이상치 후보 비율

전체 수치형 변수 중 후보 비율 상위 6개; 후보는 오류가 아니라 검토 대상

변수	후보 비율	후보 수
Overall_Cond	8.6%	252
SalePrice	4.68%	137
Lot_Area	4.33%	127
Total_Bsmt_SF	4.2%	123
Bedroom_AbvGr	2.66%	78
Gr_Liv_Area	2.56%	75

권장 전처리 순서

- 결측 의미 보존 — Garage_Yr_Blt 159건 중 157건은 Garage_Cars=0; Has_Garage를 만들고 ‘차고 없음’과 진짜 누락 2건을 분리한다. Total_Bsmt_SF, Garage_Cars 각 1건은 원자료 확인 후 0 또는 조건부 중앙값으로 보완한다.
- 오류·중복 검증 — 2207년을 수정/결측화하고, 중복 3행이 동일 거래인지 확인 후 제거한다. 극단값은 영향도 분석 전 일괄 삭제하지 않는다.
- 분포 안정화 — SalePrice, Lot_Area, Gr_Liv_Area는 log1p 후보. 지하실 면적은 0이 구조적이므로 Has_Basement와 함께 분리한다.
- 범주 처리 — Kitchen_Qual, Exter_Qual은 순서형 인코딩; Neighborhood, House_Style은 원-핫 인코딩. 희소 범주는 Other 통합을 검토하고 학습 데이터에서만 기준을 정한다.
- 스케일링·검증 — 거리/규제 기반 모델에는 수치 스케일링을 적용하고, 모든 변환·대치·인코딩은 파이프라인 안에서 학습 세트에만 fit한다. 로그 타깃 모델은 원 단위 MAE/RMSE도 함께 비교한다.

한계와 다음 질문

본 분석은 단변량·이변량 EDA이며 시간·판매조건 등 생략 변수의 영향은 확인하지 못했다. 다음 단계에서는 (1) 고면적·저가격 3건 포함/제외 민감도, (2) 품질×생활면적 상호작용, (3) 지역별 표본 불균형을 고려한 교차검증, (4) 원 타깃 대비 로그 타깃의 검증 오차를 비교한다.

자료: day16 배포본 `ames\_housing\_edu.csv` · 분석일: 2026-08-05