

[실습] Question Driven EDA



제출 날짜

2026.08.05

캠퍼스

판교캠퍼스

소속/조

5반 4조

수업


Feature Engineering

팀원

김민지, 김지영, 박영신
박지훈, 윤명진, 홍은비

1. Key Issue

Issue 01




Garage_Yr_Blt에 존재할 수 없는 연도 2207가 존재함

최댓값이 2207인데 데이터의 최신 연도는 2010이다. 히스토그램 축이 2200까지 늘어난 반면 막대는 2010 이하에만 있어 바로 확인된다. **2007 오타로 판단**이 된다.

해결방안

결측 159건을 Has_Garage 플래그로 분리한다.

Issue 02



표본 1~2건짜리 범주 인코딩과 데이터 분할에서 학습이 깨지는 현상

이런 범주는 train/test 분할 시 한쪽에만 존재해 인코딩 차원이 불일치하고, 박스플롯에서도 **표본 1~2건의 상자는 통계적 해석이 불가능함**

해결방안

희소 범주는 Other로 통합하고, 품질 변수는 Po와 Fa를 병합한다.

Issue 03

	count	mean	std	min	25%	50%	75%	max
SalePrice	2930.00	180796.06	79886.69	12789.00	129500.00	160000.00	213500.00	755000.00
Overall_Qual	2930.00	6.09	1.41	1.00	5.00	6.00	7.00	10.00
Overall_Cond	2930.00	5.56	1.11	1.00	5.00	5.00	6.00	9.00
Gr_Liv_Area	2930.00	1499.69	505.51	334.00	1126.00	1442.00	1742.75	5642.00
Lot_Area	2930.00	10147.92	7880.02	1300.00	7440.25	9436.50	11555.25	215245.00
Year_Built	2930.00	1971.36	30.25	1872.00	1954.00	1973.00	2001.00	2010.00
Total_Bsmt_SF	2929.00	1051.61	440.62	0.00	793.00	990.00	1302.00	6110.00
Garage_Cars	2929.00	1.77	0.76	0.00	1.00	2.00	2.00	5.00
Garage_Yr_Blt	2771.00	1978.13	25.53	1895.00	1960.00	1979.00	2002.00	2207.00
Full_Bath	2930.00	1.57	0.55	0.00	1.00	2.00	2.00	4.00
Bedroom_AbvGr	2930.00	2.85	0.83	0.00	2.00	3.00	3.00	8.00

	count	unique	top	freq
Neighborhood	2930	28	NAmes	443
House_Style	2930	8	1Story	1481
Kitchen_Qual	2930	5	TA	1494
Exter_Qual	2930	4	TA	1799

변수 단위 차이와 스케일링


가격과 면적처럼 범위가 큰 변수는 거리·회귀 기반 모델에서 영향력이 과도해질 수 있으므로 스케일링이 필요하다. **왜도가 강한 변수는 로그 변환을 검토**하되, 트리 모델은 스케일링의 영향이 작다.

해결방안

스케일러를 적용하고, 왜도가 강한 변수는 로그 변환을 병행한다.

2. Key Insight


Insight 01



생활 면적과 품질이 주택가격에 미치는 영향

동일한 면적에서도 고품질 주택의 중앙가격이 약 50% 높았다. 따라서 면적과 품질을 함께 고려하고, 대형·저가 이상치 3건은 별도 확인이 필요하다.

Insight 02



고가 주택으로 인한 가격 분포의 우측 편향

평균가격은 180,796으로 중앙가격 160,000보다 약 13% 높고, 왜도도 1.74로 오른쪽 꼬리가 길다. 따라서 중앙값이 대표값으로 더 적절하며, 회귀분석에서는 $\log_{1p}(\text{SalePrice})$ 변환을 고려할 필요가 있다.

Insight 03

Missing_Count	Missing_Ratio(%)
159	5.43
1	0.03
1	0.03

	Missing_Count	Missing_Ratio(%)
Garage_Yr_Blt	159	5.43
Total_Bsmt_SF	1	0.03
Garage_Cars	1	0.03

결측치의 유형과 처리- 결측 자체가 시설 부재 정보

Garage_Yr_Blt 결측 대부분은 차고가 없다는 의미지만, Total_Bsmt_SF와 Garage_Cars의 결측은 **NaN일 가능성이 높다**. 비율은 6% 이하로 낮지만 결측 원인에 따라 구분하여 처리해야 한다.