

3조 실습 결과 - sLLM 실행 및 비교

과정명	sLLM 구현 및 Fine Tuning
조원	김동빈, 김상우, 박영신, 윤명진, 홍은비
작성일	2026. 08. 18

1. 범용 LLM, Base, Instruct 단일 턴 및 멀티턴 비교

범용 LLM vs Base vs Instruct 결과 비교표

프롬프트	범용 LLM (ChatGPT-5.6 Sol)	sLLM-Base (Qwen2.5-1.5B)	sLLM-Instruct (Qwen2.5-1.5B-Instruct)
사실 질문 세종대왕이 만든 문자는 무엇인가요?	질문의 의도를 파악하여 정답을 안정적으로 제시	세종대왕이 만든 문자를 ‘조선 자유자치’ 라고 잘못 답하고 동 일 내용을 반복	최종적으로 ‘한글’ 이라고 정답 을 제시했으나 설명 중 일부 부 정확한 정보가 포함됨
한 문장 요약 인공지능 발 전에 따른 산 업 자동화	핵심 내용을 지시에 맞게 한 문장으로 요약	원문을 반복하고 새로운 내용 을 덧붙이며 ‘한 문장 요약’ 지 시를 제대로 수행하지 못함	한 문장으로 요약하여 지시 형 식을 잘 따랐으나 원문에 없던 내용을 일부 추가
추론 문제 안경을 쓰지 않은 여학생 수	조건을 계산하여 8명 도출	계산 과정에서 조건을 잘못 연 결하여 15명이라는 오답 도출	중간 계산에서 조건을 잘못 적 용하여 10명이라는 오답 도출
멀티턴 제주 코스 추 천 → 1박 2 일로 압축	이전 대화의 대상을 이해 하고 후속 요구에 맞게 답 변 가능	제주도 코스를 생성하지 못하 고 동일한 문장을 반복했으며 두 번째 턴에서도 대화를 이어 가지 못함	이전 맥락은 인지했으나 장소 환각과 일정 구분이 미흡함

Q. 단일턴 비교와 멀티턴 대화에서 관찰한 차이중 가장 인상적이었던 차이는 무엇이었고 그로부터 어떤 시사점을 얻었나요?

A. 조원별 실행 결과를 종합하면, Base 모델에 비해 Instruct 모델은 지시 형식 준수와 멀티턴 문맥 유지 능력이 크게 개선된 모습을 보였다. 다만 일부 조원 결과에서는 사실 오류나 추론 오답이 나타나, Instruction Tuning이 대화 형식과 지시 수행 능력을 향상시키더라도 사실 정확도와 추론 능력까지 보 장하지는 않는다는 점을 확인했다. 따라서 실제 서비스에서는 모델 크기뿐 아니라 튜닝 방식과 대화 이 력 관리가 중요하며, 자연스러운 응답과 정확성은 별도로 검증해야 한다고 보았다.

2. 특화 SQL 모델과 특화 튜닝의 필요성

Q. 특화 SQL 모델을 관찰하고 "왜 특화 튜닝이 필요한가"에 대해보고, Day2 파인튜닝 실습에서 확인하고 싶은 것은 무엇인가요?

A. 작은 모델이라도 특정 업무에 맞게 튜닝하면 JOIN, 필터링, 집계, 정렬과 같은 도메인 패턴을 집중적으로 학습하여 특정 작업에서 필요한 정확도와 일관성을 효율적으로 높일 수 있다는 점에서 특화 튜닝이 필요하다고 보았다. Day2에서는 파인튜닝 전후의 성능 변화뿐 아니라, 학습 데이터의 양과 품질, LoRA와 같은 경량 파인튜닝 방식의 효과, 학습률 및 Epoch 등 하이퍼파라미터의 영향, 학습되지 않은 질문에 대한 일반화 성능, 그리고 특화 성능 향상 과정에서 기존 범용 능력이 얼마나 감소하는지 등을 확인해 보고자 한다.

3. 추가 질문

Q1. 범용 LLM이 sLLM-Instruct보다 나은 답을 냈다면, 그 이유를 "모델 크기"라고 단정할 수 있을까요? 단정할 수 없다면 왜인지, 또 어떻게 하면 "크기 효과"만 따로 확인할 수 있을지 설명해보세요.

A. 범용 LLM의 성능이 더 좋았다고 해서 모델 크기 때문이라고 단정할 수는 없으며, 학습 데이터와 튜닝 방식, 프롬프트, 추론 설정, 외부 도구 사용 등의 차이도 영향을 준다. 크기 효과만 확인하려면 같은 모델 계열에서 크기 외의 조건을 최대한 동일하게 맞추고 동일한 평가 데이터로 반복 비교해야 한다. 결국 이번 실험만으로는 모델 크기와 다른 요인의 영향을 분리하기 어렵다.

Q2. SLM-SQL-0.5B에게 방금 전 단일턴 비교에서 썼던 프롬프트(사실질문/추론문제)를 그대로 넣어보세요. 특화 튜닝이 SQL 성능을 올린 대신 무엇을 잃었을까요?

A. SQL 특화 모델은 SQL 생성에서는 높은 성능을 보였지만, 일반 사실 질문에서 잘못된 답을 생성하고 추론 문제에서도 조건을 혼동하는 모습을 보였다. 이를 통해 SQL 특화 모델에서 일반 상식, 논리/수리 추론, 자연스러운 질의응답과 같은 범용 능력이 상대적으로 낮게 나타나는 것을 확인했다. 다만 이것이 특화 튜닝으로 인해 감소한 것인지는 동일한 0.5B 기반 모델의 튜닝 전후를 직접 비교해야 확인할 수 있다.

Q3. 여러분이 회사에서 '고객 문의에 SQL을 자동 생성해주는 기능'을 만든다면, 오늘 본 세 가지(범용 LLM API, sLLM Instruct, 특화 튜닝 모델) 중 무엇을 쓰겠습니까? 비용/속도/정확도 관점에서 설명해보세요.

A. 조원들은 대체로 SQL 특화 튜닝 모델이 비용과 속도, 사내 데이터 보안, SQL 정확도 측면에서 장기적으로 가장 적합하다고 보았지만, 서비스 초기에는 범용 LLM API를 활용해 데이터를 축적하는 전략도 제시되었다. 특화 모델에 필요한 데이터셋(질문/SQL 쌍)은 실제 문의가 쌓여야 만들어지므로, 초기에는 API로 SQL을 생성·검증하며 사내에서 데이터셋을 구축한 뒤 데이터와 비용 조건이 갖춰지면 특화 모델로 전환하자는 의견이었다. 다만 스키마 반출이 금지된 환경이라면 처음부터 특화 모델을 써야 한다는 점도 언급되었다. 따라서 실제 환경에서는 특화 모델을 기본으로 사용하거나 단계적으로 전환하되, 복잡하거나 모호한 요청은 범용 LLM으로 보완하고 생성 SQL에 별도의 검증 절차를 적용하는 하이브리드 구조가 가장 현실적이라는 의견으로 정리되었다.