

Vector DB 실습 1·2 결과 보고서

판교 5반 홍은비 | 2026.10.07 | 질문별 검색·답변·RAGAS 비교

1. 실습 범위와 구성

실습 PDF 5개에서 텍스트를 추출해 500자 크기·50자 중첩으로 분할하였다. 총 1,329개 청크를 BGE-M3의 1,024차원 벡터로 변환하고, 같은 벡터를 FAISS HNSW 인덱스와 Qdrant 컬렉션에 저장하였다. 이후 Dense 검색, BM25, RRF 결합, BGE-Reranker 재정렬을 차례로 비교하였다.

생성 답변은 GPT-4o mini가 검색 문맥 5개를 근거로 작성했다. RAGAS는 Faithfulness, Answer Relevancy, Context Precision without reference를 사용했다. 아래 수치는 한 질문씩 실험한 결과이며 여러 질문에 대한 평균이 아니다.

2. 실습 1 — FAISS·Qdrant 검색과 필터

질문 “HBM이란 무엇인가?”에서 FAISS와 Qdrant의 상위 5개 청크 순서는 동일했다. 1위는 삼일회계법인 「글로벌 반도체 산업 전망 2026」 64쪽의 HBM 시장 자료였고, 이어 「AI 반도체 기술 및 산업 동향」 11~12쪽과 「AI 반도체 강국도약 가이드라인」 112쪽이 검색됐다.

Qdrant에서 페이지 50 이상 조건을 적용하자 11~12쪽 결과가 빠지고, 삼일회계법인 64쪽·가이드라인 112쪽·ETRI 전략 108쪽 등이 상위에 나타났다. 페이지 메타데이터가 저장돼 있어 검색 대상을 조건으로 제한할 수 있음을 확인했다.

검증 항목	관찰 결과
청크·벡터	1,329개 / 1,024차원
FAISS·Qdrant 상위 5	“HBM이란 무엇인가?”에서 순위 일치
Qdrant page ≥ 50	11~12쪽 결과 제외, 64·112·108쪽 등 반환

근거: data/ingest.log, data/search_filter_page50.log.

3. 실습 2 — HBM 검색 단계 비교

같은 질문 “HBM 반도체”에 대해 Dense 1위는 청크 #1297(「AI 반도체 기술 및 산업 동향」 12쪽), BM25 1위는 #1295(같은 자료 11쪽)였다. RRF 결합 뒤 #1298이 1위로 올라왔다. BGE-Reranker를 적용한 최종 1위는 #953(「AI 반도체 강국도약 가이드라인」 8쪽)이었다.

RRF 단계에서 HBM 키워드가 포함된 청크의 순위가 바뀐 것은 확인된다. 그러나 Reranker의 1위 #953은 HBM 자체보다 NPU·AI ASIC 설명에 가까워, 순위 변화가 언제나 검색 품질 향상을 뜻하지는 않았다.

검색 단계	Top-5 청크 ID
Dense	#1297, #1298, #953, #856, #1257
BM25	#1295, #1259, #960, #1298, #1021
Hybrid (RRF)	#1298, #1295, #1297, #1259, #1009
Hybrid + Reranker	#953, #1295, #1296, #1297, #857

답변 기준	Faithfulness	Answer Relevancy	Context Precision
Dense	1.000	0.438	1.000
Hybrid (RRF)	1.000	0.521	1.000
Hybrid + Reranker	1.000	0.427	1.000

이 질문에서는 Hybrid의 답변 관련성(0.521)이 Dense(0.438)와 Reranker(0.427)보다 높았다. 다른 두 지표는 세 단계 모두 1.000으로 구별되지 않았다. 따라서 이번 한 건으로 Reranker가 최종 답변 품질을 개선했다고 결론내리기 어렵다.

근거: data/compare_hbm_semiconductor.log, data/ragas_results.json.

4. 통합 질문 실행

질문: “보고서들을 종합해 생성형 AI가 요구하는 핵심 반도체 기술과, 한국이 우선 강화해야 할 분야를 설명하십시오”

Dense와 Hybrid의 상위 5개 청크는 모두 「AI 반도체 강국도약 가이드라인」에서 나왔다. Reranker의 상위 5개에는 이 보고서 외에 「AI 반도체 기술 및 산업 동향」 1쪽의 AI GPU·NPU·HBM·PIM·CXL 설명이 포함됐다. 여러 보고서를 활용한다는 통합 질문의 취지에는 Reranker 문맥이 더 가까웠다.

검색 문맥을 종합하면, 생성형 AI에는 높은 연산 성능뿐 아니라 메모리 대역폭과 전력 효율을 뒷받침할 AI GPU·NPU, HBM·PIM·CXL 등이 중요하다. 국내에는 HBM·첨단 패키징의 강점이 있으므로 이를 유지하면서 펌리스, AI 프로세서 설계, 시스템 소프트웨어 및 플랫폼 역량을 함께 강화할 필요가 있다. 이 문장은 검색 결과를 바탕으로 정리한 답변이며, 보고서 전체를 검토한 정책 결론은 아니다.

답변 기준	Faithfulness	Answer Relevancy	Context Precision
Dense	1.000	0.531	1.000
Hybrid (RRF)	1.000	0.531	1.000
Hybrid + Reranker	0.875	0.536	1.000

Reranker는 답변 관련성 0.536으로 가장 높았지만, Faithfulness는 0.875로 낮아졌다. 기술 항목을 더 넓게 가져온 효과와 근거 일치도를 함께 확인해야 한다. 점수 차이는 작고 평가 질문이 한 개이므로 일반화하지 않는다.

근거: data/integrated_compare.log, data/integrated_results.json; 「AI 반도체 강국도약 가이드라인」 13·31·49·115쪽, 「AI 반도체 기술 및 산업 동향」 1쪽.

5. RAG 설정 시 주요 고려 사항 — 실습 결과에 따른 판단

① 청크 크기와 문서 전처리: 500자 청크는 빠르게 검색하기 좋았지만, 표나 페이지 경계에 걸린 설명은 잘릴 수 있다. 실제 PDF 추출 문장에도 표 제목과 본문이 붙은 부분이 있었다. 표·도표를 별도 처리하고, 청크에 문서명과 페이지를 함께 보관하는 편이 답변 근거 확인에 유리하다고 본다.

② 한국어 키워드 검색: BM25는 HBM 같은 고유명사를 보완했지만 통합 질문에서는 ETRI의 무인체 기술이나 일반 AI 서비스 문장도 상위에 올랐다. 한국어 형태소 분석과 핵심 용어 추출을 적용하고, Dense-BM25 후보의 실제 관련성을 질문별로 비교할 필요가 있다.

③ 재정렬과 문맥 수: Reranker는 후보 20개를 다시 채점해 순서를 크게 바꿨다. 그러나 HBM 질문에서 1위가 직접적인 HBM 설명이 아니었다. 점수만 믿기보다 Top-5 출처와 질문 일치 여부를 확인하고, 복합 질문은 여러 문서가 함께 들어오도록 문맥 선택을 조정하는 것이 적절하다.

④ 평가 해석: 이번 Context Precision은 정답 문장이 없는 방식이어서 생성 답변을 기준으로 문맥을 판정한다. 답변 생성과 평가에 같은 GPT-4o mini를 사용했고, 질문도 두 개뿐이다. 별도 정답·서로 다른 유형의 질문을 준비하고 사람이 일부 답변을 확인해야 점수를 더 신뢰할 수 있다.

종합하면, 검색 방식 하나를 고정하기보다 질문 유형에 맞춰 검색 결과와 근거를 점검해야 한다. 이번 결과에서는 Hybrid가 HBM 질문에 유리했고, 통합 질문에서는 Reranker가 문서 범위를 넓혔지만 근거 충실도는 조금 낮았다.

제출 자료 구성

실습 코드(lab.py, ragas_eval.py), requirements 파일, README, 실행 결과 JSON 및 로그, 본 보고서와 사용한 PDF 5개를 함께 묶었다. .env, 모델 캐시, 가상환경, 원본 임베딩 배열 및 인덱스는 제외했다.